

Local LLM Denemeleri ve Gözlem Raporu

1. Çalışmanın Amacı

Machine Learning konusu kapsamında daha detaylı ve sağlam verilere sahip olmak adına yapılan bir deneydir. LM Studio kuruldu, farklı model aileleri indirildi ve aynı sorularla karşılaştırma yapıldı.

Bu çalışmada özellikle şu soruların cevabını gözlemlemeye çalıştım:

- Local LLM çalıştırmak pratikte nasıl bir şey?
- Farklı modeller aynı prompt'a nasıl cevap veriyor?
- Hızlı cevap veren model her zaman daha iyi mi?
- Prompt netleşince cevap gerçekten değişiyor mu?
- Temperature değeri cevabın tarzını ve riskini etkiliyor mu?
- Modellerin "Hallucination" davranışına yatkınlığı ne oranda?

2. Kullanılan Modeller

Model	Genel amaç	İlk izlenim
Gemma 4 E4B	Teknik açıklama ve Türkçe cevap kalitesini görmek	En dengeli model gibi durdu. Cevapları iyi ama uzun yazma eğilimi var.
Phi 3.5 Mini Instruct	Küçük ve hızlı model davranışını görmek	Çok hızlı cevap verdi. Fakat teknik açıklama ve Türkçe kalitesi zayıf kaldı.
Llama 3.1 8B Instruct	Popüler 8B instruct model davranışını görmek	Çok hızlıydı ama Türkçesi garipti. Bazı tanımlar yarım veya oturmamış gibiydi.
Mistral 7B Instruct v0.3	Mistral ailesini test etmek	Hızlıydı ama bu testlerde bağlam ve Türkçe teknik açıklama tarafında zayıf kaldı.

3. Sabit Soru Testi

Modelleri adil karşılaştırmak için aynı iki soru kullanıldı. Böylece her modelin hızını, Türkçe kalitesini, teknik doğruluğunu ve talimata uyumunu yan yana değerlendirmek daha kolay oldu.

Soru	Prompt	Neyi ölçmek için soruldu?
1	LLM nedir? Kısa ama teknik olarak doğru şekilde açıkla.	Genel LLM tanımı, Türkçe anlatım, kısa cevap isteğine uyma.
2	Token, context window ve temperature kavramlarını bir LLM üzerinden basit örneklerle açıkla. Cevabı kısa tut.	Token, context window ve temperature kavramlarını aynı cevapta toparlayabilme.

4. Model Bazlı Gözlemler

4.1 Gemma 4 E4B

Gemma ilk testlerde en dengeli görünen model oldu. LLM, token, context window ve temperature gibi teknik kavramları genel olarak doğru açıkladı. Türkçesi diğer modellere göre daha düzgün ve anlaşılırdı.

Eksik tarafı ise cevapları uzatmasıydı. Promptta "kısa" dememe rağmen çoğu zaman başlıklı, detaylı ve uzun cevaplar verdi. Yani bilgi kalitesi iyi ama komutları uygulama açısından çok başına buyruk.

4.2 Phi 3.5 Mini Instruct

Phi modelinin en dikkat çeken tarafı hız oldu. Cevabı neredeyse anlık verdi. LM Studio tarafında Gemma'daki gibi ayrı bir "thinking" süresi görünmedi. Kalite tarafında ise Gemma kadar güven vermedi. Türkçe cümleler garipti, bazı teknik açıklamalar eksik veya yüzeysel kaldı. Kısa cevap verme konusunda iyiydi ama teknik doğruluk açısından zayıftı.

4.3 Llama 3.1 8B Instruct

Llama da çok hızlı cevap verdi. Fakat Türkçesi beklediğim kadar doğal değildi. Bazı tanımlar yarıda kalmış veya çeviri gibi hissettirdi. Özellikle context window açıklaması tam oturmadı.

Bu testte Llama için genel izlenim şu oldu: hız iyi, ama Türkçe teknik açıklama kalitesi Gemma'nın gerisinde kaldı.

4.4 Mistral 7B Instruct v0.3

Mistral bu testlerde en problemli modellerden biri oldu. "LLM nedir?" sorusunda LLM kısaltmasını yapay zeka bağlamındaki "Large Language Model" olarak değil de, hukuk alanındaki LL.M. gibi yorumladı. Bu ciddi bir bağlam hatasıydı.

Prompt "Yapay zeka bağlamında LLM yani Large Language Model nedir?" diye netleştirilince doğru alana geçti. Yani model aslında tamamen kullanılamaz değil fakat belirsiz promptta yanlış bağlama kayma riski yüksek çıktı. Türkçe anlatımda da doğal olmayan ifadeler vardı.

Model	Hız	Türkçe kalite	Teknik doğruluk	Genel sonuç
Gemma 4 E4B	Orta	İyi	İyi	En dengeli model. Uzun yazıyor ama teknik olarak daha güvenilir.
Phi 3.5 Mini	Çok hızlı	Zayıf/orta	Zayıf/orta	Hızlı ama açıklama kalitesi zayıf.
Llama 3.1 8B	Çok hızlı	Orta	Orta/zayıf	Hız iyi ama Türkçe ve tanımlar tam oturmadı.
Mistral 7B	Çok hızlı	Zayıf	Zayıf	Belirsiz promptta yanlış bağlama kaydı.

5. Prompt Değişimi Testi

Bu bölümde en iyi sonuç alınan model olduğu için Gemma ile devam ettim. Gemma ile aynı kavramı farklı prompt seviyelerinde sordum. Amaç, prompt içindeki bağlam değiştikçe modelin cevabının nasıl yön değiştirdiğini görmekti.

Prompt	Süre	Cevabın yönü	Gözlem
Context neden önemlidir?	16.09 sn	Genel bağlam	Model konuyu dilbilim, iletişim, yapay zeka, kültür ve karar verme gibi çok geniş bir çerçevede anlattı.
LLM'lerde context window neden önemlidir?	24.29 sn	LLM odaklı	Cevap token sınırı, modelin anlık belleği, uzun doküman, RAG ve lost in the middle gibi teknik konulara kaydı.
PDF soru-cevap sistemi geliştirirken context window neden önemlidir? 4 maddede kısa açıkla.	23.96 sn	Proje odaklı	Cevap doğrudan PDF QA sistemine bağlandı. Belge bütünlüğü, bilgi sentezi ve hallucination riski gibi konular öne çıktı.

Buradaki ana gözlem: prompt ne kadar genel olursa cevap o kadar geniş ve dağınık oluyor. Prompt içine "LLM", "context window" ve "PDF soru-cevap sistemi" gibi bağlamlar eklendikçe model cevabı daha hedefli ve işimize yarar hale getiriyor.

6. Temperature Testi

Temperature ayarını da Gemma üzerinde denedim. Aynı prompt kullanıldı, sadece temperature değeri değiştirildi.

Prompt şu şekildeydi: "RAG sistemi nedir? PDF soru-cevap sistemi üzerinden kısa ve teknik şekilde açıkla."

Temperature	Süre	Gözlem
0.1	13.63 sn	Cevap daha kontrollü, klasik ve sistematikti. Teknik olarak iyiydi ama yine uzundu.
0.7	12.08 sn	Cevap biraz daha örnekli ve doğal oldu. Genel yapı 0.1'e çok benzer kaldı.
1.4	13.87 sn	Ana mantık doğru kaldı ama "Göömülme", "Vekter" gibi dil hataları ve fazla kesin ifadeler arttı.

Bu testten çıkan sonuç: temperature düşükken model daha güvenli ve tahmin edilebilir cevap veriyor. Temperature yükselince cevap tamamen bozulmadı ama kelime seçimleri daha serbestleşti, bazı yazım hataları ve riskli ifadeler arttı. Yani yüksek temperature bazen daha canlı cevap üretebilir ama teknik doğruluk isteyen işlerde hata riskini de artırabilir.

7. Hallucination Testi

Hallucination tarafını görmek için uydurma bir model adı üzerinden test yaptım. Soru, “XZ-91 Türkçe LLM modeli” hakkında parametre sayısı, context window değeri ve eğitim veri setleri gibi teknik detayları istemek üzerine kuruldu.

Gemma bu testte daha güvenli davrandı. Böyle bir model hakkında güvenilir bilgiye sahip olmadığını söyledi ve parametre sayısı ya da eğitim veri seti gibi detaylar uydurmadı.

Mistral ise daha problemlili davrandı. XZ-91’i gerçek bir modelmiş gibi kabul etti, hatta İngilizce cevap verdi. Net parametre sayısı sallamadı ama “detaylar geliştiriciler tarafından açıklanmamış” gibi doğrulanmamış bir varsayım kurdu. Bu da hallucination sayılır, çünkü olmayan veya doğrulanmamış bir varlığı gerçekmiş gibi ele aldı.

Model	Davranış	Sonuç
Gemma 4 E4B	Bilmediğini söyledi, teknik detay uydurmadı.	Daha güvenli.
Mistral 7B	XZ-91’i gerçekmiş gibi kabul etti ve İngilizce cevap verdi.	Hallucination eğilimi gösterdi.
Llama 3.1 8B	XZ-91 modelini gerçekmiş gibi ele aldı. Parametre sayısını bulamadığını söyledi ama context window değerini 2048 olarak verdi ve TDK sözlüğü, kitaplar, makaleler, forumlar gibi veri setleri uydurdu.	Net hallucination yaptı. Olmayan/doğrulanmamış model için teknik detay üretmeye çalıştı.
Phi 3.5 Mini	XZ-91 hakkında spesifik bilgiye sahip olmadığını söyledi. Ancak cevabı çok da temiz değildi; genel LLM bilgileri verdi ve Türkçesi yer yer bozuktuk.	Teknik detay uydurmadı, bu yüzden hallucination açısından Llama ve Mistral’a göre daha güvenli davrandı. Ama cevap kalitesi düşüktü.

8. Genel Değerlendirme

Bugünkü local LLM denemelerinde hız tek başına kalite anlamına gelmedi. Phi, Llama ve Mistral çok hızlı cevap verdi ama teknik doğruluk ve Türkçe anlatımda Gemma kadar güvenilir değildi. Gemma daha yavaş kaldı ama cevapların genel kalitesi daha iyiydi.

Benim bu denemelerden çıkardığım en net sonuç: PDF soru-cevap sistemi gibi teknik doğruluk isteyen bir işte sadece hızlı cevap veren modeli seçmek mantıklı değil. Modelin Türkçesi, bağlamı doğru yakalaması, bilmediği yerde uydurmaması ve teknik kavramları düzgün açıklaması daha önemli.

Bu yüzden şu an küçük PDF soru-cevap sistemi için ilk aday olarak Gemma daha mantıklı duruyor. Eksisi uzun cevap yazması ve biraz daha yavaş olması. Ama güvenilirlik tarafında diğerlerine göre daha iyi bir ilk izlenim verdi.

9. Local LLM Kullanmanın Artı ve Eksi Tarafları

Artıları	Eksileri
Veri dışarı gitmeden localde çalışıyor. Bu özellikle özel PDF veya şirket içi dokümanlarda avantaj.	Kalite seçilen modele çok bağlı. Küçük modeller hızlı ama teknik olarak zayıf kalabiliyor.
İnternet olmasa bile model dosyası indirildikten sonra temel kullanım yapılabilir.	Model indirmek disk alanı ve zaman istiyor.
Farklı modelleri aynı ortamda deneyip karşılaştırmak kolay oluyor.	Türkçe cevap kalitesi her modelde aynı değil.
LM Studio ile kurulum yapmak kolay ve hızlı oluyor.	Bazı modeller belirsiz promptlarda yanlış bağlama kayabiliyor veya hallucination yapabiliyor.

10. Sonuç

Bu çalışmada LM Studio kullanılarak farklı local LLM modelleri denendi. Gemma, Phi, Llama ve Mistral modellerine aynı sorular sorularak cevap hızları, Türkçe anlatım kaliteleri, teknik doğrulukları, prompt uyumları, prompt değişimine verdikleri tepkiler, temperature ayarından nasıl etkilendikleri ve hallucination davranışları gözlemlendi.

Genel değerlendirme sonucunda Gemma modeli, bu aşamada başlangıç ve orta seviye bir local LLM projesi için en uygun model olarak öne çıktı. Gemma'nın cevapları bazı durumlarda gereğinden uzun olsa da teknik doğruluk, Türkçe açıklama kalitesi ve belirsiz konularda daha güvenli davranması açısından diğer modellere göre daha başarılı olduğu görüldü.