

RAG Doküman Soru-Cevap Sistemi

Kısa Teknik Rapor

1. Amaç

Bu çalışmada PDF veya TXT formatındaki dokümanların yüklenebildiği ve yalnızca yüklenen doküman üzerinden soru-cevap yapılabildiği temel bir RAG sistemi geliştirildi. Sistem, kullanıcının sorusuna en yakın doküman parçalarını buluyor, bu parçaları seçilen dil modeline veriyor ve cevabın hangi kaynaklara dayandığını ekranda gösteriyor.

2. Sistem Akışı

- PDF veya TXT dokümanı yüklenir.
- Dokümandaki metin çıkarılır ve sayfa bilgisi saklanır.
- Metin başlık ve paragraf yapısı korunarak chunk'lara ayrılır.
- Her chunk için embedding oluşturulur ve ChromaDB içerisine kaydedilir.
- Kullanıcının sorusu embedding'e dönüştürülür ve en alakalı ilk üç chunk bulunur.
- Bulunan kaynaklar Cloud Gemini veya Local Gemma modeline context olarak gönderilir.
- Üretilen cevap ile kullanılan chunk ve sayfa bilgileri birlikte gösterilir.

3. Kullanılan Yapılar

Bileşen	Kullanılan yapı
Arayüz	Streamlit
PDF okuma	PyMuPDF
Embedding modeli	intfloat/multilingual-e5-small
Embedding boyutu	384
Vector database	ChromaDB
Cloud LLM	gemini-3.5-flash
Ana local LLM	google/gemma-4-e4b
Local bağlantı	LM Studio native API

4. Chunking ve Retrieval

İlk denemede metin yalnızca kelime sayısına göre bölündü. Bu yöntemde farklı başlıkların ve paragrafların aynı chunk içinde birleştiği görüldü. Daha sonra başlık ve paragraf duyarlı chunking yapısına geçildi. Böylece her chunk kendi bölüm başlığıyla birlikte tutuldu ve metinlerin karışması azaltıldı.

Kullanılan ayarlar: 120 kelimelik chunk size, 25 kelimelik overlap ve top-k 3. Hazırlanan beş soruluk test setinde doğru kaynak her soruda ilk sırada bulundu. Bu test seti üzerinde Top-1 ve Hit@3 sonucu 5/5 olarak ölçüldü. Bu sonuç yalnızca kullanılan doküman ve hazırlanan sorular için geçerlidir.

5. Cloud ve Local Model Karşılaştırması

Cloud Gemini ve Local Gemma aynı soru, aynı prompt ve aynı kaynak chunk'lar kullanılarak karşılaştırıldı. Böylece sonuç farkının retrieval kısmından değil, cevap üreten modelden kaynaklanması sağlandı.

Soru	Gemini	Gemma	Sonuç
XZ-91 hallucination farkı	2.13 sn	3.84 sn	İkisi de doğru
Phi neden güvenilir bulunmadı?	1.32 sn	4.74 sn	İkisi de doğru
Prompta bağlam eklenince ne değişti?	6.85 sn	8.51 sn	İkisi de doğru

Soru	Gemini	Gemma	Sonuç
Local kullanımın artıları ve eksileri	1.80 sn	4.90 sn	İkisi de doğru
Hızlı modeller neden seçilmedi?	1.82 sn	2.28 sn	İkisi de doğru
Ortalama	2.78 sn	4.85 sn	-

Gemini genel olarak daha hızlı, daha akıcı ve daha ayrıntılı cevaplar verdi. Gemma ise daha kısa ve doğrudan cevaplar üretti. Local modelin en önemli avantajı, kaynak metinlerin cihaz dışına çıkmaması ve internet olmadan çalışabilmesidir.

6. Negatif Testler

İlk negatif testte dokümanda hiç geçmeyen bir şirket gelir hedefi soruldu. İkinci testte ise Gemma, token ve context window ifadeleri dokümanda bulunmasına rağmen sayısal context window kapasitesi soruldu. İki model de iki testte bilgi uydurmadı ve cevabın yüklenen dokümanda bulunmadığını söyledi.

Test	Durum	Sonuç
Şirketin 2027 yılı gelir hedefi	Dokümanda konu da cevap da yok	İki model de cevap yok dedi
Gemma context window kapasitesi	Konu ve anahtar kelimeler var, sayı yok	İki model de sayı uydurmadı

7. Başarılı ve Sınırlı Kalan Noktalar

- Cevabı tek bir bölümde bulunan sorularda doğru chunk ilk sıraya geldi.
- Birden fazla chunk gerektiren sorularda iki model de bilgileri birleştirebildi.
- Cevabı bulunmayan sorularda bilgi uydurulmadı.
- Taranmış ve metin katmanı olmayan PDF dosyaları için OCR desteği bulunmuyor.
- PDF içindeki tablolar bazı durumlarda düz metne dönüşüyor ve satır-sütun yapısı tam korunmuyor.
- Cloud kullanımında yalnızca ilgili chunk'lar gönderilse de bu metinler üçüncü taraf API ile paylaşılmış oluyor.

8. Sonuç

Çalışma sonunda PDF ve TXT dokümanları üzerinden çalışan temel bir RAG soru-cevap sistemi oluşturuldu. Sistem dokümanı işleyip kaynak parçaları bulabiliyor, Cloud Gemini veya Local Gemma ile cevap üretebiliyor ve kullanılan kaynakları gösterebiliyor. Yapılan testlerde iki model de dokümana bağlı kaldı. Gemini hız ve anlatım kalitesinde öne çıkarken, Gemma gizlilik ve çevrimdışı kullanım açısından avantaj sağladı.